Análise Tática de Partidas de Futebol Usando *Deep Learning*: Reconhecimento de Eventos de Finalização e Modelagem de *Expected Goals* (xG)

Eduardo Larson[1], **Daniel Rigoni**[1]

[1]Departamento de Ciência da Computação
Universidade Estadual do Centro-Oeste (UNICENTRO)
Guarapuava – PR – Brasil

eduardolarson05@gmail.com, danielrigoni@unicentro.br

Abstract. *Automated tactical analysis of football matches from conventional broadcast video addresses a significant limitation in sports analytics, as current high-precision tracking systems depend on expensive specialized infrastructure unavailable in most competitions. This work proposes and implements an integrated computational system for player and ball tracking, mapping their positions onto real field coordinates, automatically identifying shots, and calculating Expected Goals (xG) directly from television broadcasts. The proposed XGNet model achieved a high accuracy rate (AUC-ROC of* 0.8096 *and Brier Score of* 0.0800*) when predicting the probability of goals using a dataset of* $60,148$ *shots. Additionally, a customized ball tracking strategy increased the ball detection rate from* 40.4% *to* 65.5%*. The complete system was validated across four distinct competitions (UEFA Euro 2020, FIFA World Cup, Copa Libertadores, and Campeonato Brasileiro Série B). The final evaluation achieved high precision in identifying shots, ranging between* 0.667 *and* 1.000*, though the detection rate decreased on lower-quality broadcasts, establishing that the challenge of continuously tracking the ball is the primary technical area for future system improvements.*

Keywords: *Computer Vision; Deep Learning; Object Detection; Expected Goals; Tactical Analysis; Football.*

Resumo. *A análise tática automatizada de partidas de futebol a partir de vídeos convencionais de transmissão atende a uma limitação importante na análise esportiva, visto que os sistemas atuais de rastreamento dependem de infraestrutura cara e especializada, indisponível na maioria das competições. Este trabalho propõe e implementa um sistema computacional integrado para rastreamento de jogadores e da bola, mapeando suas posições em coordenadas reais do campo, identificando automaticamente finalizações e calculando a probabilidade de gol (Expected Goals - xG) diretamente de transmissões televisivas. O modelo proposto, XGNet, alcançou um alto índice de acerto (AUC-ROC de* $0{,}8096$ *e Brier Score de* $0{,}0800$*) na previsão de gols utilizando um conjunto de* 60.148 *chutes. Além disso, uma estratégia customizada elevou a taxa de detecção da bola de* $40{,}4\%$ *para* $65{,}5\%$*. O sistema completo foi validado em quatro competições distintas (UEFA Euro 2020, Copa do Mundo FIFA, Copa Libertadores e Campeonato Brasileiro Série B). A avaliação final obteve alta precisão no reconhecimento de chutes (entre* $0{,}667$ *e* $1{,}000$*), embora a taxa de*

captura tenha diminuído em transmissões de menor qualidade técnica, estabelecendo o desafio de rastrear a bola continuamente como o principal fator limitante para futuras melhorias.
Palavras-Chave: *Visão Computacional; Aprendizado Profundo; Detecção de Objetos; Expected Goals; Análise Tática; Futebol.*

1. Introdução

O futebol é o esporte de maior audiência e impacto econômico no mundo, movimentando bilhões de dólares anuais em direitos de transmissão, transferências de jogadores e patrocínios [Deloitte 2023]. Nesse contexto, a capacidade de extrair informações táticas objetivas a partir de vídeos de partidas tornou-se um diferencial competitivo significativo para clubes, comissões técnicas e plataformas de análise esportiva. Enquanto grandes clubes europeus dispõem de sistemas proprietários de rastreamento baseados em câmeras fixas de alta precisão, como o TRACAB e o Hawk-Eye [Link 2018], a vasta maioria das partidas disputadas no mundo, incluindo competições amadoras, semiprofissionais e ligas de menor expressão, não conta com qualquer forma de instrumentação especializada. A análise tática dessas partidas permanece, em grande parte, dependente de observação manual e julgamento subjetivo [Reep and Benjamin 1968, Link 2018].

O avanço das redes neurais profundas para tarefas de visão computacional abriu uma alternativa concreta a esse cenário. Arquiteturas de detecção de objetos em tempo real, como a família YOLO, demonstraram capacidade de identificar e localizar múltiplos objetos em sequências de vídeo com precisão e velocidade compatíveis com aplicações práticas [Redmon et al. 2016, Jocher et al. 2023]. Paralelamente, o desenvolvimento de métodos robustos de calibração de câmera baseados em reconhecimento de linhas e pontos-chave do campo permitiu o mapeamento das posições detectadas para coordenadas reais do gramado sem a necessidade de *hardware* especializado [Magera et al. 2024]. A combinação dessas tecnologias cria a possibilidade de construir sistemas *end-to-end* de análise tática a partir de vídeos convencionais de *broadcast*.

Dentro desse domínio, a métrica de *Expected Goals* (xG) ocupa posição central na análise estatística moderna do futebol. Concebida como uma quantificação probabilística da qualidade de uma finalização, expressa como a probabilidade de um chute resultar em gol dado o contexto espacial e situacional em que ocorreu, o xG tornou-se uma das ferramentas mais adotadas por analistas de desempenho esportivo nas últimas décadas [Tippett 2019, Hewitt and Karakuş 2023]. Modelos tradicionais de xG são alimentados por dados estruturados de eventos anotados manualmente por empresas especializadas, como a StatsBomb[1] e a Opta[2]. Essa dependência representa uma barreira de acesso significativa: partidas sem cobertura de dados estruturados simplesmente não podem ser analisadas por esses modelos. A extração automática das *features* de xG diretamente a partir do vídeo, posição da bola, ângulo de finalização e pressão defensiva, eliminaria essa barreira e democratizaria o acesso à análise tática quantitativa.

Este trabalho propõe e implementa um *pipeline* computacional *end-to-end* para análise tática automática de partidas de futebol a partir de vídeos de *broadcast*. O sistema

[1] `https://statsbomb.com/`
[2] `https://opta.statscore.com/`

integra detecção de objetos baseada em redes neurais profundas, rastreamento multi-objeto com filtragem de Kalman, calibração de campo via reconhecimento de pontos-chave com o modelo PnLCalib [Magera et al. 2024], detecção heurística de eventos de finalização e modelagem de xG com uma rede neural profunda treinada sobre dados abertos da StatsBomb. O *pipeline* é capaz de processar vídeos de competições profissionais sem qualquer instrumentação adicional além da câmera de *broadcast*, produzir como saída o valor de xG de cada finalização detectada, visualizações táticas em tempo real e estatísticas de posse de bola.

A principal contribuição técnica do trabalho reside na integração de componentes heterogêneos, detecção, rastreamento, homografia e modelagem estatística, em um sistema coeso e funcional, com ênfase na robustez do rastreamento da bola. Para esse componente, foram implementadas duas estratégias complementares: um detector especializado baseado no YOLOv8x[3] retreinado com dados do SoccerNet Tracking [Vandeghen et al. 2022] e um rastreador com filtragem de Kalman e *Optical Flow* de Lucas-Kanade [Lucas and Kanade 1981] como mecanismo de predição durante oclusões. O modelo de xG, por sua vez, foi implementado como uma rede neural profunda em PyTorch [Paszke et al. 2019] com quatro camadas ocultas, *BatchNorm* e *Dropout*, treinada com *GroupShuffleSplit* por partida para evitar *data leakage* entre treino e teste.

O trabalho está organizado da seguinte forma: A seção 2 apresenta o referencial teórico, cobrindo os fundamentos de detecção de objetos, rastreamento multi-objeto, calibração de câmera em esportes e modelagem de *Expected Goals*; a seção 3 descreve a metodologia, detalhando cada componente do *pipeline* e o protocolo de validação adotado; a seção 4 apresenta e discute os resultados quantitativos e qualitativos obtidos e a seção 5 conclui o trabalho, sintetizando as contribuições realizadas, as limitações identificadas e as direções para trabalhos futuros.

2. Referencial Teórico

Esta seção apresenta os fundamentos teóricos necessários para a compreensão do trabalho. Inicialmente, discute-se o contexto da análise tática no futebol moderno e a evolução dos métodos quantitativos aplicados ao esporte. Em seguida, são apresentadas as técnicas de detecção de objetos com redes neurais profundas, rastreamento multi-objeto, calibração de câmera e homografia em ambientes esportivos, e modelagem de *xG*, componentes centrais da arquitetura proposta.

2.1. Análise Tática no Futebol Moderno

A análise quantitativa do futebol tem raízes históricas modestas. Os primeiros trabalhos a tratar o jogo como objeto de estudo estatístico rigoroso remontam à década de 1960, quando Reep e Benamin [1968] publicaram uma análise sistemática sobre padrões de posse de bola e sequências de passes em competições inglesas. Embora metodologicamente limitados pelos padrões atuais, esses estudos pioneiros estabeleceram a premissa fundamental que orienta o campo até hoje: o desempenho esportivo pode ser descrito, medido e comparado por meio de variáveis quantificáveis extraídas dos eventos de uma partida.

[3] https://github.com/ultralytics/ultralytics

O estado da arte nessa área combina dados de rastreamento de posição com câmeras de alta precisão, que registram as coordenadas de todos os jogadores e da bola a taxas de 25 a 50 Hz, com modelos de aprendizado de máquina capazes de inferir padrões táticos complexos a partir dessas trajetórias espaço-temporais. Fernandez e Bornn [2018] demonstraram, por exemplo, que é possível quantificar o espaço criado por movimentos sem bola a partir de coordenadas de posicionamento, abrindo caminho para métricas táticas que transcendem os eventos discretos tradicionais. No entanto, a dependência de *hardware* especializado de rastreamento restringe essas abordagens a competições com infraestrutura adequada, excluindo a grande maioria das partidas disputadas globalmente.

2.2. Detecção de Objetos com Redes Neurais Profundas

A detecção de objetos em imagens e vídeos é uma das tarefas centrais da visão computacional e consiste em identificar simultaneamente a classe e a localização de múltiplos objetos em uma cena. As abordagens contemporâneas baseiam-se em redes neurais convolucionais profundas, cuja capacidade de aprender representações hierárquicas de características visuais, desde bordas e texturas em camadas iniciais até padrões semânticos complexos em camadas profundas, as torna superiores a métodos clássicos baseados em engenharia manual de *features* [Goodfellow et al. 2016].

A família de detectores YOLO (*You Only Look Once*), introduzida por [Redmon et al. 2016], representa a principal linha de desenvolvimento para detecção em tempo real. A ideia central da arquitetura é tratar a detecção como um único problema de regressão sobre uma grade de células da imagem, eliminando o estágio separado de geração de propostas de região que caracterizava detectores anteriores como o Faster R-CNN. Essa escolha arquitetural resulta em velocidade de inferência significativamente superior com custo moderado em precisão. Versões subsequentes refinaram progressivamente o equilíbrio entre velocidade e acurácia: o YOLOv8, lançado pela Ultralytics em 2023 [Jocher et al. 2023], introduziu uma cabeça de detecção sem âncoras (*anchor-free*) e melhorias na extração de *features* multi-escala, atingindo desempenho de estado da arte em *benchmarks* como o MS COCO.

No contexto específico do futebol, a detecção de objetos enfrenta desafios particulares. Jogadores frequentemente se ocluem mutuamente, especialmente em situações de disputa de bola e em cobranças de escanteio ou falta. A bola, por sua vez, apresenta dimensão reduzida em relação ao *frame*, tipicamente entre 15 e 40 *pixels* de diâmetro em vídeos de *broadcast*, e pode exibir forte *motion blur* durante chutes de alta velocidade, reduzindo drasticamente sua resposta nos mapas de ativação da rede. Para mitigar esse problema, técnicas como o *Slicing Aided Hyper Inference* (SAHI) [Akyon et al. 2022] propõem dividir o *frame* em regiões sobrepostas antes da inferência, preservando a resolução efetiva do objeto de interesse e aumentando o *recall* em cenários com objetos pequenos. O presente trabalho incorpora uma variante dessa técnica especificamente para o detector de bola, conforme será descrito na Seção 3.1.

2.3. Rastreamento Multi-Objeto

O rastreamento multi-objeto (*Multi-Object Tracking*, MOT) consiste em associar, ao longo de uma sequência de *frames*, as detecções de objetos individuais de forma a manter identidades consistentes ao longo do tempo. O desafio consiste, fundamentalmente, em um problema de associação de dados: dado um conjunto de detecções no *frame* atual e

um conjunto de trajetórias ativas, determinar qual detecção corresponde a qual trajetória, considerando oclusões, entradas e saídas de cena [Zhang et al. 2022].

O paradigma dominante atual, denominado *tracking-by-detection*, separa explicitamente as etapas de detecção e associação. Nessa abordagem, um detector de objetos independente produz as detecções *frame* a *frame*, e um módulo de associação, baseado em distâncias de aparência, movimento previsto ou combinações dos dois, realiza o casamento entre detecções e trajetórias. O algoritmo ByteTrack [Zhang et al. 2022] demonstrou que o uso de detecções de baixa confiança, tipicamente descartadas por abordagens anteriores, melhora significativamente a continuidade das trajetórias em situações de oclusão parcial. O BotSORT [Aharon et al. 2022], utilizado neste trabalho para o rastreamento de jogadores, estende o ByteTrack com um módulo de Re-ID baseado em aparência e compensação de movimento da câmera, tornando-o mais robusto a mudanças de ângulo de câmera características de transmissões esportivas.

Para o rastreamento específico da bola, abordagens baseadas puramente em associação por proximidade espacial mostram-se insuficientes. A bola frequentemente aparece fora do *frame*, é ocluída por jogadores, ou tem sua detecção confundida com marcações circulares do campo, como o ponto de pênalti e a marca central. O Filtro de Kalman [Kalman 1960], formulado como um estimador recursivo ótimo para sistemas lineares com ruído gaussiano, oferece uma solução natural para esse problema: o filtro mantém um modelo dinâmico do estado da bola, posição e velocidade no plano da imagem, e rejeita detecções cujo desvio em relação à predição, medido pela distância de Mahalanobis, excede um limiar configurável. Esse mecanismo de *gating* impede que saltos para posições estáticas, características de falsos positivos de marcações do campo, corrompam a trajetória estimada. Durante períodos de oclusão prolongada, o *Optical Flow* [Lucas and Kanade 1981], que rastreia o deslocamento aparente de uma região da imagem entre *frames* consecutivos com base em gradientes locais de intensidade, é empregado como preditor alternativo de posição quando o detector falha.

2.4. Calibração de Câmera e Homografia em Esportes

A transformação das coordenadas de *pixels* detectados no *frame* em coordenadas métricas reais do campo é um requisito fundamental para qualquer análise tática quantitativa. Essa transformação é mediada pela homografia, uma matriz de dimensão 3×3 que mapeia pontos de um plano em outro sob projeção perspectiva. No contexto esportivo, a homografia estabelece a correspondência entre o plano do gramado, modelado como superfície plana com dimensões conhecidas, e o plano da imagem capturada pela câmera de *broadcast*.

A estimativa robusta dessa homografia a partir de vídeos de transmissão televisiva é um problema não trivial. Câmeras de *broadcast* operam com lentes de comprimento focal variável, sem parâmetros intrínsecos conhecidos a priori, e realizam movimentos contínuos de *pan*, *tilt* e *zoom* ao longo da partida. Abordagens clássicas baseadas em detecção de linhas do campo via transformada de Hough mostraram-se frágeis em condições reais, produzindo homografias instáveis quando poucas linhas são visíveis. O modelo PnLCalib [Magera et al. 2024], adotado neste trabalho, representa o estado da arte nessa tarefa. Baseado na arquitetura HRNet [Sun et al. 2019] para detecção de pontos-chave e segmentos de linha do campo, o PnLCalib estima os parâmetros da câmera por meio de votação heurística sobre as correspondências entre os elementos detectados

e um modelo 3D do campo, com refinamento não-linear baseado em restrições ponto-na-linha. A qualidade da homografia estimada é avaliada pelo erro de reprojeção, calculado como a distância média em *pixels* entre os pontos-chave detectados e sua projeção esperada pela matriz estimada.

Para atenuar a instabilidade da homografia entre *frames* consecutivos, causada por ruído de detecção e por movimentos abruptos de câmera, aplica-se um Filtro de Kalman sobre os nove elementos da matriz. Embora essa suavização ignore as restrições algébricas de uma homografia válida, produz resultados aceitáveis para câmeras de *broadcast* com movimentos lentos, conforme discutido por [Homayounfar et al. 2017].

2.5. *Expected Goals* (xG): Origem, Evolução e Modelagem

A métrica de xG quantifica a qualidade de uma oportunidade de gol atribuindo a cada finalização uma probabilidade entre 0 e 1 de resultar em gol, condicionada ao contexto espacial e situacional em que o chute foi efetuado. A intuição subjacente é direta: um chute de dentro da pequena área, sem marcação e com ângulo aberto para o gol, tem probabilidade objetivamente maior de resultar em gol do que um chute de fora da área com ângulo fechado, independentemente do desfecho observado em uma única tentativa. A soma dos valores de xG de todas as finalizações de uma equipe ao longo de uma partida fornece uma estimativa do número esperado de gols, que tende a ser mais preditiva do desempenho futuro do que o placar observado [Tippett 2019].

Os modelos contemporâneos de xG variam significativamente em sofisticação. Modelos básicos utilizam apenas distância e ângulo de finalização em relação ao gol como *features* preditoras, alcançando AUC-ROC (*Area Under the Receiver Operating Characteristic Curve*), métrica amplamente utilizada para avaliar a capacidade discriminativa de classificadores binários, da ordem de $0{,}75$ a $0{,}78$ em conjuntos de dados típicos. Modelos mais elaborados incorporam dezenas de variáveis contextuais, tipo de ação que precedeu o chute, posição dos defensores, posição do goleiro, fase do jogo, velocidade da bola, e empregam arquiteturas de aprendizado de máquina mais expressivas, como *gradient boosting* e redes neurais, alcançando AUC-ROC acima de $0{,}80$ [Hewitt and Karakuş 2023]. A principal limitação de todos esses modelos quando aplicados a vídeos arbitrários é a dependência de dados de eventos anotados manualmente: as *features* são extraídas de bancos de dados estruturados, não do vídeo em si.

O presente trabalho propõe extrair essas *features* diretamente das posições detectadas pelo *pipeline* de visão computacional, fechando essa lacuna para o subconjunto de *features* espacialmente observáveis: distância ao gol, ângulo de finalização, parte do corpo utilizada, pressão defensiva aproximada e número de defensores no cone de visada.

A arquitetura XGNet, proposta neste trabalho para a modelagem do xG, é uma rede neural profunda implementada em PyTorch [Paszke et al. 2019] com quatro camadas ocultas de dimensões 64, 32, 16 e 8 neurônios, respectivamente, com normalização de *batch* (*BatchNorm*) e regularização por *Dropout* entre as camadas. A escolha de *BatchNorm* é motivada pelo severo desbalanceamento de classes presente nos dados de treinamento, aproximadamente $11{,}5\%$ de finalizações resultam em gol, que pode causar instabilidade nos gradientes durante o treinamento em *minibatches* com poucos exemplos positivos. O *Dropout*, por sua vez, atua como regularizador implícito, reduzindo o risco de memorização de padrões espúrios da classe majoritária. A calibração das probabilida-

des de saída é realizada por *Platt Scaling* [Platt 1999], que ajusta uma regressão logística sobre os logits da rede no conjunto de teste, garantindo que os valores de xG produzidos sejam probabilidades bem calibradas e não apenas escores de *ranking*.

3. Metodologia

O sistema proposto é estruturado como um *pipeline* sequencial de processamento de vídeo, no qual cada módulo recebe como entrada os resultados do módulo anterior e produz saídas que alimentam os estágios subsequentes. A Figura 1 ilustra a arquitetura geral do *pipeline*, composta por seis etapas principais: (*i*) detecção de objetos; (*ii*) rastreamento; (*iii*) classificação de times; (*iv*) calibração de campo e mapeamento espacial; (*v*) detecção de eventos de finalização e; (*vi*) modelagem de xG. O processamento é realizado *frame* a *frame* sobre vídeos de *broadcast* de futebol, sem qualquer instrumentação adicional além da câmera de transmissão.

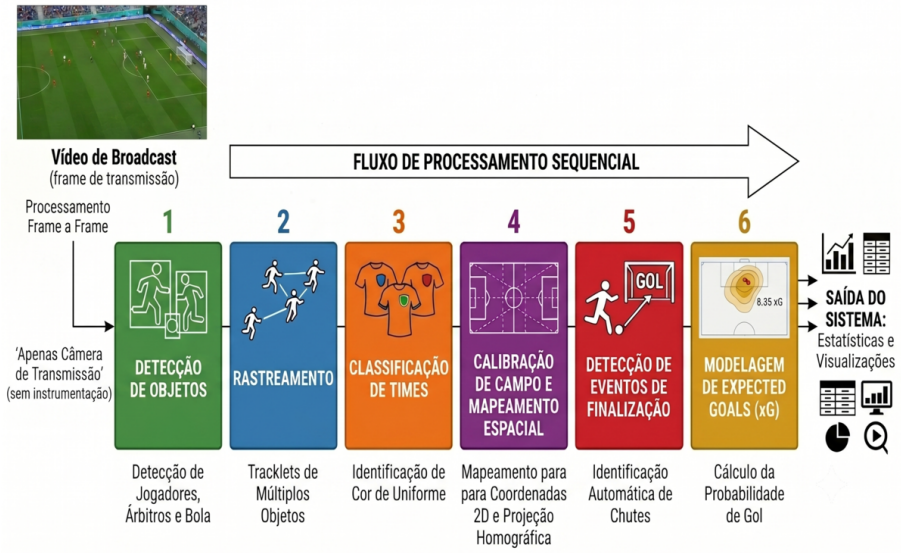


Figura 1: Arquitetura geral do *pipeline* de análise tática.

A distância de Mahalanobis, empregada no mecanismo de *gating* do Filtro de Kalman para rejeição de detecções improváveis, é definida como:

$$d_M = \sqrt{(\mathbf{z} - \mathbf{H}\hat{\mathbf{x}})^\top \mathbf{S}^{-1} (\mathbf{z} - \mathbf{H}\hat{\mathbf{x}})}, \tag{1}$$

onde $\mathbf{z}$ é o vetor de medição, $\hat{\mathbf{x}}$ é o estado predito pelo filtro, $\mathbf{H}$ é a matriz de observação e $\mathbf{S} = \mathbf{H}\mathbf{P}\mathbf{H}^\top + \mathbf{R}$ é a covariância da inovação.

As *features* de distância ao gol (d_{gol}) e ângulo de finalização (θ), utilizadas pelo modelo XGNet, são calculadas a partir das coordenadas do chute (x, y) e das coordenadas do gol (x_{gol}, y_{gol}):

$$d_{gol} = \sqrt{(x_{gol} - x)^2 + (y_{gol} - y)^2}, \tag{2}$$

$$\theta = \left| \arctan\left(\frac{y_{poste_esq} - y}{x_{gol} - x}\right) - \arctan\left(\frac{y_{poste_dir} - y}{x_{gol} - x}\right) \right|, \tag{3}$$

onde y_{poste_esq} e y_{poste_dir} são as coordenadas verticais dos postes esquerdo e direito do gol, respectivamente.

A função de perda *BCEWithLogitsLoss* com ponderação de classes, utilizada no treinamento do XGNet para tratar o desbalanceamento entre gols e não-gols, é definida por:

$$\mathcal{L} = -\frac{1}{N}\sum_{i=1}^{N}[w_+ \cdot y_i \log \sigma(\hat{y}_i) + (1 - y_i)\log(1 - \sigma(\hat{y}_i))], \tag{4}$$

onde $y_i \in \{0, 1\}$ é o rótulo real, $\hat{y}_i$ é o logit predito pela rede, $\sigma(\cdot)$ é a função sigmoide e $w_+ = N_{neg}/N_{pos}$ é o peso de balanceamento proporcional à razão entre exemplos negativos e positivos.

As métricas de avaliação do detector de finalizações são formalmente definidas a partir de quatro quantidades: verdadeiros positivos (TP, finalizações reais corretamente detectadas), falsos positivos (FP, detecções realizadas pelo sistema que não correspondem a finalizações reais), falsos negativos (FN, finalizações reais não detectadas pelo sistema) e verdadeiros negativos (TN, clipes de controle corretamente classificados como ausentes de finalização). A partir dessas quantidades:

$$\text{Precisão} = \frac{TP}{TP + FP}, \tag{5}$$

$$\text{Recall} = \frac{TP}{TP + FN}, \tag{6}$$

$$F_1 = \frac{2 \cdot \text{Precisão} \cdot \text{Recall}}{\text{Precisão} + \text{Recall}}. \tag{7}$$

Em síntese, a Precisão mede a proporção de detecções corretas entre todas as detecções realizadas pelo sistema; o Recall mede a proporção de finalizações reais efetivamente detectadas; e o F1-Score representa a média harmônica entre as duas métricas, equilibrando o *tradeoff* entre precisão e abrangência.

3.1. Detecção e Rastreamento de Objetos

A detecção de objetos é realizada por dois modelos distintos, cada um especializado em uma categoria de objetos. Para jogadores, goleiros e árbitros, utiliza-se um modelo YOLOv8x treinado sobre um conjunto de dados composto por imagens anotadas de transmissões televisivas de futebol, provenientes do repositório Roboflow[4] por meio da biblioteca Supervision[5]. O modelo opera sobre *frames* redimensionados para 640×640 *pixels* e classifica as detecções em quatro classes: bola (classe 0), goleiro (classe 1), jogador (classe 2) e árbitro (classe 3). O *threshold* de confiança para aceitação de detecções foi fixado em $0{,}55$, valor determinado empiricamente para equilibrar precisão e *recall* no domínio de *broadcast* europeu.

Para a detecção da bola, adota-se um segundo modelo YOLOv8x especializado, retreinado a partir dos pesos do modelo geral sobre o conjunto SoccerNet Tracking [Vandeghen et al. 2022], que contém sequências anotadas de partidas profissionais

[4] `https://roboflow.com`

[5] `https://github.com/roboflow/supervision`

com anotações específicas de posição da bola *frame* a *frame*. A motivação para essa especialização reside nas características particulares da bola como objeto de detecção: dimensão reduzida no *frame*, tipicamente entre 15 e 40 *pixels* de diâmetro em *broadcast* de 1080p, combinada com forte *motion blur* durante chutes de alta velocidade e frequente oclusão parcial por jogadores. O retreino especializado elevou o *recall* da detecção de bola de $40{,}4\%$ para $65{,}5\%$ no conjunto de validação, conforme será reportado na Seção 4.

Para mitigar adicionalmente o problema de objetos pequenos, o detector de bola emprega uma técnica de recorte dinâmico inspirada no SAHI [Akyon et al. 2022]: o *frame* é dividido em regiões sobrepostas antes da inferência, preservando a resolução efetiva da bola e aumentando a sensibilidade dos mapas de ativação da rede convolucional para objetos de pequena dimensão. As detecções obtidas nas diferentes regiões são fundidas por *Non-Maximum Suppression* antes de serem passadas ao módulo de rastreamento.

Adicionalmente, um filtro geométrico é aplicado sobre as detecções de bola antes do rastreamento: *bounding boxes* com área superior a 350 *pixels* quadrados, razão de aspecto superior a $2{,}0$ ou centradas na faixa superior de 20% do *frame*, região correspondente às placas publicitárias e microfones de *broadcast*, são descartadas como falsos positivos determinísticos. Essa restrição física é motivada pela observação de que objetos com essas características geométricas não podem corresponder a uma bola de futebol em campo, independentemente do escore de confiança atribuído pelo detector.

O rastreamento de jogadores, goleiros e árbitros é realizado pelo algoritmo BoT-SORT [Aharon et al. 2022], que combina associação por *Intersection over Union*, razão entre a área de sobreposição e a área de união de duas *bounding boxes*, utilizada como medida de similaridade espacial entre detecções, com compensação de movimento da câmera. O rastreamento é executado sem módulo de Re-ID, o que implica que oclusões prolongadas podem resultar na atribuição de novos identificadores a jogadores já presentes na cena, limitação documentada na Seção 5.

O rastreamento da bola é tratado separadamente por um Filtro de Kalman de quatro estados $[x, y, v_x, v_y]$, onde x e y representam a posição em *pixels* do centro da bola e v_x, v_y representam as componentes de velocidade. O modelo dinâmico assume movimento com velocidade constante entre *frames* consecutivos, com ruído de processo calibrado empiricamente. Detecções candidatas são aceitas com base na distância de Mahalanobis em relação ao estado predito, com limiar de 3 desvios padrão. Durante períodos em que nenhuma detecção aceitável está disponível, por oclusão ou falha do detector, o *Optical Flow* [Lucas and Kanade 1981] é empregado como preditor alternativo de posição, rastreando o deslocamento aparente da região correspondente à última posição conhecida da bola entre *frames* consecutivos. Uma verificação adicional de estacionaridade rejeita detecções que permanecem na mesma posição por 8 ou mais *frames* consecutivos, eliminando falsos positivos causados por jogadores caídos ou marcações estáticas do campo.

O desempenho dos detectores de objetos é avaliado pelo mAP50 (*Mean Average Precision* com limiar de *Intersection over Union* de $0{,}50$), métrica padrão em *benchmarks* de detecção de objetos que computa a área sob a curva Precisão-Recall para cada classe e calcula a média entre todas as classes, considerando uma detecção correta quando a sobreposição entre a *bounding box* predita e a anotação de referência supera 50%.

Complementarmente, o mAP50-95 agrega esse cálculo sobre limiares de *Intersection over Union* entre $0{,}50$ e $0{,}95$, fornecendo uma avaliação mais exigente da precisão de localização.

Como tentativa de refinamento secundário, foi desenvolvido um módulo em cascata baseado em regressão de *heatmap* gaussiano com arquitetura U-Net [Ronneberger et al. 2015] e *encoder* MobileNetV2 [Sandler et al. 2018], treinado com 20.115 *patches* do SoccerNet Tracking. Embora o módulo tenha atingido PCK@0.1 de $99{,}6\%$ em avaliação isolada, sua integração em cascata resultou em degradação do desempenho por *domain shift*, sendo documentado como resultado negativo e direcionado a trabalhos futuros (Seção 5).

3.2. Classificação de Times

A classificação dos jogadores detectados em dois times é realizada por meio do componente *TeamClassifier* da biblioteca Supervision[6], que aplica agrupamento K-Means sobre *embeddings* de cor extraídos dos recortes de cada jogador. O classificador é treinado automaticamente sobre *frames* amostrados do próprio vídeo sendo processado, sem necessidade de anotação prévia ou configuração manual de cores. O treinamento é realizado uma única vez por jogo, no início do processamento, a partir de um clipe de calibração representativo do jogo em questão.

A atribuição de times a goleiros é tratada separadamente, dado que a cor do uniforme do goleiro frequentemente difere da cor do uniforme dos demais jogadores do mesmo time. A resolução é feita geometricamente: cada goleiro é atribuído ao time cuja mediana espacial de posições dos jogadores detectados é mais próxima da posição do goleiro no campo. O uso da mediana, em vez da média, torna o método robusto à presença de *outliers* causados por jogadores fora de posição.

Árbitros são excluídos explicitamente do processo de classificação de times, prevenindo que seus uniformes, geralmente de cor distinta, contaminem os *clusters* aprendidos pelo K-Means e degradem a qualidade da separação entre os dois times.

3.3. Calibração de Campo e Mapeamento Espacial

O mapeamento das posições detectadas em *pixels* para coordenadas métricas reais do campo é realizado em três etapas: estimativa da homografia, suavização temporal e transformação de coordenadas.

A estimativa da homografia utiliza o modelo PnLCalib [Magera et al. 2024], que emprega duas redes HRNet [Sun et al. 2019] treinadas sobre o conjunto SoccerNet para detectar, respectivamente, pontos-chave e segmentos de linha do campo visíveis no *frame*. O PnLCalib estima os parâmetros extrínsecos e intrínsecos da câmera por votação heurística sobre as correspondências entre os elementos detectados e um modelo 3D do campo com dimensões padrão UEFA ($105\,\text{m} \times 68\,\text{m}$), com refinamento não-linear baseado em restrições ponto-na-linha. A qualidade da homografia estimada é avaliada pelo erro médio de reprojeção sobre os pontos-chave detectados: erros abaixo de 50 *pixels* resultam em *quality score* próximo a $1{,}0$, enquanto erros superiores degradam o *score* proporcionalmente. *Frames* com *quality score* abaixo de $0{,}15$ têm sua homografia descartada em favor do último valor válido.

[6] `https://github.com/roboflow/supervision`

A suavização temporal da homografia é realizada por um segundo Filtro de Kalman aplicado sobre os nove elementos da matriz $H(3\times3)$. Embora essa abordagem ignore formalmente as restrições algébricas de uma homografia válida, produz suavização satisfatória para câmeras de *broadcast* com movimentos lentos, conforme observado empiricamente. Em situações de falha prolongada da estimativa, quando nenhuma homografia válida é produzida por mais de 15 *frames* consecutivos, o sistema utiliza a predição do Kalman como *fallback*, mantendo a continuidade do mapeamento espacial.

O sistema de coordenadas adotado posiciona a origem no canto inferior esquerdo do campo, com o eixo X orientado ao longo da linha lateral e o eixo Y orientado perpendicularmente, cobrindo o intervalo $[0, 105]$ metros no eixo X e $[0, 68]$ metros no eixo Y. As coordenadas do sistema PnLCalib, que utiliza origem centrada no campo, são convertidas para esse sistema por translação antes de serem utilizadas pelos módulos subsequentes.

3.4. Detecção de Eventos de Finalização

A detecção de eventos de finalização é baseada em um conjunto de heurísticas geométricas e cinemáticas aplicadas sobre a trajetória da bola no espaço real do campo. Um evento de finalização é reconhecido quando quatro condições são satisfeitas simultaneamente.

A primeira condição verifica a proximidade espacial entre a bola e o jogador mais próximo: a distância euclidiana entre a posição projetada da bola e a posição de pé do jogador mais próximo deve ser inferior a $3{,}0$ metros. Essa restrição associa o evento ao jogador que presumivelmente efetuou o chute.

A segunda condição verifica a velocidade da bola: a magnitude do vetor velocidade estimado deve ser superior a $5{,}0$ metros por segundo. A velocidade é estimada por regressão linear sobre uma janela deslizante de 5 *frames*, com um limite físico superior de 40 m/s para rejeição de velocidades artificiais causadas por saltos de detecção.

A terceira condição verifica a proximidade da bola ao gol adversário: a distância euclidiana entre a posição da bola e o centro do gol deve ser inferior a $25{,}0$ metros. Esse limiar cobre toda a área de finalização realista e exclui ações no campo de defesa.

A quarta condição verifica o alinhamento direcional entre o vetor velocidade da bola e o vetor que aponta da posição da bola para o centro do gol: o produto interno normalizado entre esses vetores deve ser superior a $0{,}3$. Esse limiar foi determinado empiricamente sobre o conjunto de validação BEL-ITA (Jogo entre Bélgica e Itália na Euro 2020 para conjunto de Desenvolvimento): a análise dos valores observados revelou separação clara entre os dois grupos, com o menor valor registrado em finalizações reais sendo $0{,}31$ e o maior valor em eventos rejeitados por esse critério sendo $0{,}26$. Essa condição é a responsável por eliminar passes e cruzamentos na área de grande perigo que satisfariam as três condições anteriores, mas não se dirigem ao gol. Um período de *cooldown* de $3{,}0$ segundos entre detecções consecutivas previne que um único evento de finalização seja registrado múltiplas vezes.

A confiança atribuída a cada evento detectado é calculada como uma combinação ponderada de três *scores*: *score* de distância jogador-bola (peso $0{,}30$), *score* de velocidade (peso $0{,}45$) e *score* de alinhamento direcional (peso $0{,}25$). A definição dessas constantes baseou-se em uma análise manual conduzida pelo autor sobre o conjunto de dados, sendo

calibrada de forma empírica a partir de um processo interativo de ajuste, em que outras configurações de valores resultaram em percepção de piora ou estagnação nas métricas qualitativas de detecção. Dessa forma, os pesos finais refletem a importância relativa de cada critério como discriminador entre finalizações reais e falsos positivos, com a velocidade recebendo o maior peso por ser o discriminador mais robusto entre chutes e passes.

3.5. Modelagem de *Expected Goals* com XGNet

O modelo de *Expected Goals* é implementado como uma rede neural profunda denominada XGNet, desenvolvida em PyTorch [Paszke et al. 2019]. A arquitetura consiste em cinco camadas lineares com dimensões $6 \rightarrow 64 \rightarrow 32 \rightarrow 16 \rightarrow 8 \rightarrow 1$, com normalização de *batch* (*BatchNorm1d*) e regularização por *Dropout* após as três primeiras camadas ocultas. Nas camadas ocultas, utiliza-se a função de ativação ReLU (*Rectified Linear Unit*) devido à sua eficiência computacional e capacidade de mitigar o problema do gradiente evanescente (*vanishing gradient*).

A camada de saída não possui função de ativação linear acoplada, produzindo *logits* diretos. Visando a estabilidade numérica e prevenindo erros de arredondamento por subfluxo (*underflow*), a função sigmoide original foi integrada diretamente à função de perda através do *BCEWithLogitsLoss*. Por fim, aplicou-se o método de *Platt Scaling* para calibrar as probabilidades finais do modelo, ajustando os níveis de confiança das previsões aos resultados reais observados.

O modelo recebe como entrada um vetor de seis *features* extraídas automaticamente a partir das posições detectadas pelo *pipeline*: distância ao gol em metros no sistema de coordenadas StatsBomb[7] (*shot_distance*), ângulo de finalização em graus calculado entre os postes do gol (*shot_angle*), indicador binário de finalização com o pé (*body_part_foot*), indicador binário de finalização com a cabeça (*body_part_head*), distância ao defensor mais próximo em metros (*def_pressure*) e número de defensores no cone de visada de 6° em direção ao gol (*n_defenders_in_cone*). As coordenadas do *pipeline*, originadas no sistema métrico UEFA ($105\,\text{m} \times 68\,\text{m}$), são convertidas para o sistema StatsBomb ($120\,\text{m} \times 80\,\text{m}$) por fatores de escala fixos antes do cálculo das *features*, garantindo compatibilidade com o espaço de treinamento.

O treinamento utiliza dados de eventos de finalizações do StatsBomb Open Data, cobrindo 26 competições e temporadas de ligas europeias e competições internacionais, incluindo UEFA Euro, Copa do Mundo FIFA, La Liga, Premier League, Serie A, Ligue 1 e Bundesliga, com um total de 60.148 chutes, dos quais $11{,}1\%$ resultaram em gol. O severo desbalanceamento de classes é tratado por *BCEWithLogitsLoss* com *pos_weight* proporcional à razão entre exemplos negativos e positivos. A divisão entre conjuntos de treino e teste é realizada por *GroupShuffleSplit* com agrupamento por partida, garantindo que chutes de uma mesma partida não apareçam simultaneamente nos dois conjuntos, protocolo necessário para evitar *data leakage* decorrente da correlação entre eventos de uma mesma partida.

O otimizador utilizado é o Adam com taxa de aprendizado inicial de 5×10^{-4} e decaimento de peso de 1×10^{-4}. Um *scheduler ReduceLROnPlateau* reduz a taxa de

[7] `https://github.com/statsbomb/statsbombpy`

aprendizado por fator de $0{,}5$ quando a *loss* de treinamento não melhora por 10 épocas consecutivas. O treinamento é interrompido por *early stopping* com paciência de 20 épocas, sendo o melhor estado do modelo restaurado ao final. A calibração das probabilidades de saída é realizada por *Platt Scaling* [Platt 1999]: uma regressão logística é ajustada sobre os logits produzidos pelo modelo treinado no conjunto de teste, transformando os logits em probabilidades bem calibradas que correspondem a frequências observadas de gol.

3.6. Conjuntos de Dados e Protocolo de Validação

Para o treinamento do detector de jogadores, goleiros e árbitros, utiliza-se um conjunto de imagens de *broadcast* de futebol anotadas com *bounding boxes*, proveniente do repositório Roboflow, contendo imagens de transmissões televisivas europeias com as quatro classes de interesse.

Para o retreino do detector especializado de bola, utilizou-se o SoccerNet Tracking [Vandeghen et al. 2022], que contém 57 sequências de vídeo de partidas profissionais com anotações de posição de bola e jogadores no formato MOT. As anotações de bola são identificadas por meio do arquivo *gameinfo.ini* de cada sequência, que mapeia identificadores de trajetória para categorias semânticas. Após conversão para o formato YOLO, o conjunto resultante contém *frames* com anotações exclusivas de bola, distribuídos em 80% para treino e 20% para validação.

Para o treinamento e avaliação do modelo XGNet, utiliza-se o StatsBomb Open Data, que disponibiliza gratuitamente dados estruturados de eventos de partidas profissionais de múltiplas competições. Os eventos de finalização extraídos incluem localização, tipo de parte do corpo utilizada, desfecho e posições dos jogadores no *freeze frame* do chute.

A validação do *pipeline* completo é conduzida sobre cinco conjuntos de clipes de vídeo anotados manualmente, abrangendo quatro competições e contextos distintos, conforme descrito na Tabela 1. O conjunto BEL-ITA, composto por 14 clipes da partida Bélgica 1×2 Itália (UEFA Euro 2020), com duração média de 10 segundos cada, sendo 11 com finalizações reais e 3 de controle, foi utilizado como conjunto de desenvolvimento. Os demais conjuntos foram reservados exclusivamente para análise de generalização, dispostos em ordem crescente de distância do domínio de treinamento dos componentes de aprendizado profundo: o BEL-RUS testa a generalização dentro da mesma competição; o ARG-FRA estende a avaliação a outra competição internacional de alto nível com padrão de *broadcast* similar; o FLA-CAP introduz o domínio sul-americano com transmissões de estádios brasileiros; e o SAN-MIR representa o cenário de maior distância de domínio, com *broadcast* de menor qualidade técnica da Série B do Campeonato Brasileiro. As anotações de *ground truth* foram realizadas manualmente, registrando para cada clipe a ocorrência ou não de finalização real.

3.7. Declaração de Uso de Assistência por Inteligência Artificial

No desenvolvimento deste trabalho foi utilizado o assistente Claude Sonnet 4.6 (Anthropic) via *claude.ai* para revisão ortográfica, melhoria do fluxo de escrita e sugestões de arquitetura de software. Todas as decisões de projeto, implementações, experimentos e interpretações de resultados foram realizadas pelo autor.

Tabela 1: Conjuntos de validação do *pipeline* completo.

Conjunto	Competição / Contexto	Clipes	Chutes	Controle	Papel
BEL-ITA	UEFA Euro 2020	14	11	3	Desenvolvimento
BEL-RUS	UEFA Euro 2020	14	11	3	Generalização (intra-comp.)
ARG-FRA	Copa do Mundo FIFA	14	11	3	Generalização (inter-comp.)
FLA-CAP	Copa Libertadores (final)	14	11	3	Generalização (domínio sul-am.)
SAN-MIR	Campeonato Brasileiro Série B	14	12	2	Generalização (*broadcast* baixa qualidade)

4. Resultados e Discussão

Nesta seção, são analisados os resultados da detecção de objetos, a validação do detector de finalizações em diferentes cenários e o desempenho do modelo XGNet na predição de *Expected Goals* (xG).

4.1. Desempenho do Detector de Objetos

O detector de jogadores, goleiros e árbitros baseado em YOLOv8x atingiu mAP50 de $0{,}872$ e mAP50-95 de $0{,}658$ no conjunto de validação, com desempenho consistente entre as classes de jogadores (mAP50 = $0{,}928$) e árbitros (mAP50 = $0{,}878$). A classe de goleiros apresentou desempenho ligeiramente inferior (mAP50 = $0{,}829$), o que é esperado dado o menor número de instâncias disponíveis no conjunto de treinamento e a variabilidade maior de uniformes dessa categoria.

O detector especializado de bola, retreinado sobre o SoccerNet Tracking, atingiu mAP50 de $0{,}631$ e *recall* de $0{,}655$ no conjunto de validação, representando uma melhora expressiva em relação ao detector geral. A melhora de 62% no *recall*, de $40{,}4\%$ para $65{,}5\%$, é atribuída à combinação de dois fatores: a maior representatividade de instâncias de bola no conjunto de treinamento especializado e a técnica de recorte dinâmico inspirada no SAHI, que preserva a resolução efetiva da bola durante a inferência. A Tabela 2 sumariza as métricas de detecção por classe para o modelo geral, e a Tabela 3 compara o desempenho do detector de bola antes e após o retreino especializado.

Tabela 2: Métricas de detecção por classe: modelo YOLOv8x geral.

Classe	Precisão	Recall	mAP50	mAP50-95
Bola	0,940	0,404	0,507	0,270
Goleiro	0,906	0,750	0,829	0,681
Jogador	0,952	0,899	0,928	0,791
Árbitro	0,936	0,822	0,878	0,640
Geral	0,934	0,719	0,786	0,596

Tabela 3: Comparação do detector de bola antes e após retreino especializado.

Modelo	Precisão	Recall	mAP50	mAP50-95
YOLOv8x geral	0,940	0,404	0,507	0,270
YOLOv8x especializado	0,696	0,655	0,631	0,261

A queda de precisão de $0{,}940$ para $0{,}696$ no detector especializado é um *tradeoff* esperado e aceitável: o modelo anterior raramente gerava falsos positivos para a bola, mas perdia a bola com frequência. O modelo retreinado detecta mais instâncias reais ao custo

de um número maior de detecções incorretas, que são subsequentemente filtradas pelo Filtro de Kalman com *gate* de Mahalanobis e pelo filtro geométrico.

4.2. Avaliação do Detector de Finalizações

O detector de finalizações emprega as métricas de Precisão, *Recall* e F1-*Score*, formalmente definidas na Seção 3. O detector foi avaliado sobre os cinco conjuntos de validação descritos na Seção 3.6. A Tabela 4 consolida os resultados de todos os conjuntos.

Tabela 4: Métricas do detector de finalizações por conjunto de validação.

Conjunto	TP	FP	FN	TN	Precisão	Recall	F1
BEL-ITA	6	1	5	2	0,857	0,545	0,667
BEL-RUS	4	0	7	3	1,000	0,364	0,533
ARG-FRA	4	0	7	3	1,000	0,364	0,533
FLA-CAP	2	1	9	2	0,667	0,182	0,286
SAN-MIR	2	0	10	2	1,000	0,167	0,286

No conjunto de desenvolvimento BEL-ITA, a precisão de $0{,}857$ indica que o sistema apresenta baixa taxa de alarmes falsos: em 6 de cada 7 detecções, o evento corresponde a uma finalização real. O único falso positivo identificado corresponde a um passe vertical executado na frente da área, cujo vetor de velocidade satisfazia os critérios de proximidade ao gol e magnitude de velocidade, mas não representava uma finalização.

O *recall* de $0{,}545$ revela que o sistema perde aproximadamente metade das finalizações reais. O intervalo de confiança de 95% por *bootstrap* ($[0{,}273;\ 0{,}818]$) expõe a amplitude estatística inerente a um conjunto de apenas 11 eventos: as diferenças de *recall* observadas entre os cinco conjuntos de validação devem ser interpretadas com cautela, pois os intervalos de confiança se sobrepõem entre conjuntos adjacentes. O protocolo de validação deve ser entendido como um estudo piloto de viabilidade técnica, não como avaliação estatisticamente conclusiva de generalização. A análise dos cinco falsos negativos indica que a causa dominante é a falha do detector de bola: em quatro dos cinco casos, a bola não foi detectada nos *frames* críticos ao redor do evento de finalização.

Os resultados dos conjuntos de generalização revelam um padrão de *recall* decrescente consistente com o aumento da distância de domínio em relação aos dados de treinamento dos componentes de aprendizado profundo. No BEL-RUS (mesmo torneio, jogo diferente) e no ARG-FRA (Copa do Mundo FIFA), o *recall* cai para $0{,}364$, mantendo precisão perfeita. Esse padrão sugere que as heurísticas cinemáticas do detector são robustas ao domínio, mas a instabilidade do rastreamento de bola em contextos visuais ligeiramente diferentes impede o acúmulo de *frames* suficientes para disparar as condições cinemáticas em eventos legítimos. Como o detector especializado YOLOv8x e o modelo de calibração PnLCalib dependem de treinamento prévio em conjuntos compostos predominantemente por *broadcast* europeu (SoccerNet e Roboflow), variações na textura do gramado, na disposição das placas publicitárias e nas condições de iluminação dos estádios degradam a consistência dos rastreamentos.

A queda mais acentuada ocorre nos conjuntos sul-americanos. No FLA-CAP (Copa Libertadores), o *recall* atinge $0{,}182$ e a precisão cai para $0{,}667$, refletindo maior

Tabela 5: Métricas de avaliação dos modelos de xG no conjunto de teste.

Modelo	AUC-ROC	Brier Score	xG médio
XGBoost	0,7903	0,0848	0,1124
XGNet (proposto)	0,8096	0,0800	0,1111
Taxa de gol observada			0,1115
Total de chutes (treino+teste)			60.148
Competições e temporadas			26

variação nas características de transmissão em relação ao domínio de treinamento. No SAN-MIR (Série B), o *recall* atinge $0{,}167$, o valor mais baixo do protocolo, com precisão perfeita: nenhum alarme falso foi gerado, mas o sistema detectou apenas 2 das 12 finalizações reais, evidenciando que as características visuais do *broadcast* de menor qualidade técnica degradam severamente a consistência do rastreamento de bola. A ausência de falsos positivos em quatro dos cinco conjuntos confirma que as heurísticas cinemáticas são robustas ao domínio, sendo a detecção de bola o principal fator limitante em todos os contextos avaliados.

4.3. Avaliação do Modelo XGNet

O modelo XGNet foi treinado sobre 60.148 eventos de finalização extraídos do StatsBomb Open Data, cobrindo 26 competições e temporadas de ligas europeias e competições internacionais. O conjunto de teste, composto por partidas não vistas durante o treinamento, garantido pelo protocolo de *GroupShuffleSplit* por partida, continha aproximadamente 12.030 chutes. Os resultados são apresentados na Tabela 5.

A AUC-ROC de $0{,}8096$ indica que o XGNet discrimina corretamente a qualidade de finalizações em $80{,}9\%$ dos pares de comparação entre chutes que resultaram em gol e chutes que não resultaram, desempenho compatível com modelos de xG reportados na literatura para *feature sets* de complexidade similar [Hewitt and Karakuş 2023]. O *Brier Score* de $0{,}0800$ quantifica o erro quadrático médio entre as probabilidades previstas e os desfechos observados; valores abaixo de $0{,}10$ são considerados satisfatórios para modelos de classificação binária com classes desbalanceadas na proporção observada.

A proximidade entre o xG médio previsto ($0{,}1111$) e a taxa de gol observada no conjunto de dados ($0{,}111$) confirma que o modelo está globalmente calibrado: a soma dos valores de xG sobre um conjunto de partidas converge para o número esperado de gols, propriedade fundamental para o uso do xG como métrica de análise de desempenho coletivo.

Durante o desenvolvimento do modelo, foram avaliadas duas arquiteturas: um modelo baseado em *XGBoost* [Chen and Guestrin 2016] e a rede neural profunda XGNet. O *XGBoost* atingiu AUC-ROC de $0{,}7903$ e *Brier Score* de $0{,}0848$, mas apresentou colapso de probabilidade, com ausência completa de predições acima de $0{,}6$ conforme evidenciado na Figura 2, tornando-o inadequado para a modelagem de finalizações de alta periculosidade a despeito de seu desempenho discriminativo aceitável.

O XGNet, por sua vez, produziu distribuição de probabilidades mais ampla e calibração superior em toda a faixa de xG, sendo adotado como modelo final. A curva de calibração do XGNet evidencia boa aderência entre probabilidades previstas e frequências observadas na faixa de $0{,}0$ a $0{,}6$, que corresponde à grande maioria das finalizações. A

instabilidade observada na faixa de xG acima de $0{,}6$ é atribuída ao baixo número de amostras nos *bins* de alta probabilidade: chutes com xG acima de $0{,}6$ representam menos de 3% do conjunto de teste, resultando em estimativas estatisticamente ruidosas nessa faixa.

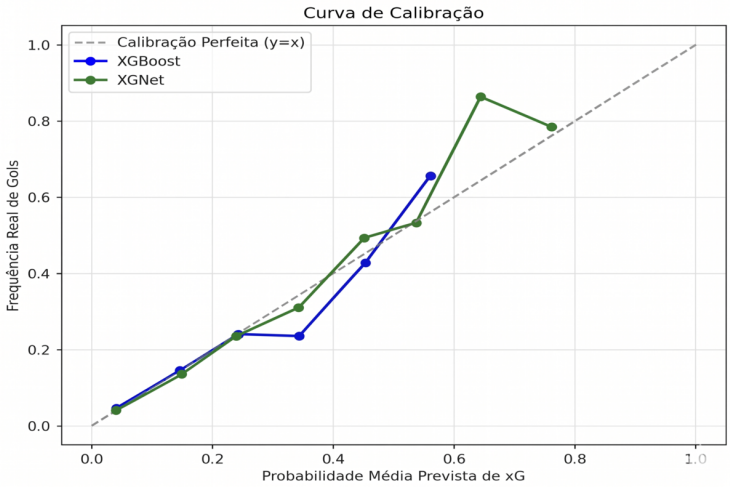


Figura 2: Curva de calibração dos modelos XGBoost e XGNet no conjunto de teste.

4.4. Análise Qualitativa do Pipeline

A análise qualitativa do *pipeline* foi conduzida sobre os vídeos processados dos clipes de validação, avaliando a consistência visual das anotações produzidas e a coerência dos valores de xG atribuídos às finalizações detectadas. A Figura 3 apresenta um exemplo de *frame* processado pelo sistema.



Figura 3: Exemplo de *frame* processado pelo *pipeline* com anotações visuais de rastreamento e minimapa tático.

O mapeamento espacial mostrou-se visualmente consistente nos clipes em que a homografia convergiu adequadamente: as posições dos jogadores projetadas no minimapa tático corresponderam às posições reais observadas no *frame*, e a bola foi corretamente

posicionada na região de finalização. O *quality score* médio da homografia nos clipes avaliados foi superior a $0{,}70$, indicando que a maioria dos *frames* apresentou estimativa de calibração de boa qualidade.

Os valores de xG atribuídos às finalizações detectadas mostraram coerência qualitativa com o contexto visual dos eventos: chutes da pequena área com ângulo aberto receberam valores entre $0{,}35$ e $0{,}52$, enquanto finalizações de fora da área com marcação próxima receberam valores entre $0{,}04$ e $0{,}09$. O único gol presente nos clipes de validação, uma finalização do canto da pequena área após jogada de bola parada, recebeu xG de $0{,}185$, consistente com a geometria da jogada: distância de $15{,}8$ m e ângulo de $12{,}7°$, reflexo da posição lateral do chute em relação ao gol.

As estatísticas de posse de bola calculadas pelo *pipeline* apresentaram coerência com o contexto das partidas avaliadas. Nos clipes do jogo Bélgica-Itália, a posse estimada variou entre 45% e 55% por time em situações de jogo aberto, e entre 15% e 85% em clipes com pressão defensiva intensa, refletindo adequadamente a dinâmica tática observada visualmente.

5. Conclusão

Este trabalho apresentou o desenvolvimento e a avaliação de um *pipeline* computacional para análise tática automática de partidas de futebol a partir de vídeos de *broadcast*, integrando técnicas de visão computacional baseadas em aprendizado profundo com modelagem estatística de *Expected Goals*. O sistema proposto é capaz de processar vídeos convencionais de transmissão televisiva sem qualquer instrumentação adicional, produzindo como saída a detecção e o rastreamento de jogadores e da bola, o mapeamento espacial de posições em coordenadas métricas reais do campo, a identificação automática de eventos de finalização, o cálculo do valor de xG correspondente e estatísticas de posse de bola.

Os resultados obtidos demonstram a viabilidade técnica da abordagem proposta. O modelo XGNet atingiu AUC-ROC de $0{,}8096$ e *Brier Score* de $0{,}0800$ sobre 60.148 finalizações, superando o *XGBoost* (AUC-ROC $0{,}7903$) tanto em discriminação quanto em calibração, confirmando que é possível construir um estimador de qualidade de finalizações a partir de *features* espaciais extraídas automaticamente por visão computacional. O detector especializado de bola elevou o *recall* de detecção de $40{,}4\%$ para $65{,}5\%$. O detector de finalizações atingiu precisão de $0{,}857$ e *recall* de $0{,}545$ no conjunto de desenvolvimento BEL-ITA, com F1 de $0{,}667$.

A validação em cinco conjuntos abrangendo quatro contextos competitivos distintos (UEFA Euro 2020, Copa do Mundo FIFA, Copa Libertadores e Campeonato Brasileiro Série B) revelou um padrão de *recall* decrescente consistente com o aumento da distância de domínio em relação ao domínio de treinamento dos componentes de aprendizado profundo, com *recall* variando de $0{,}545$ (domínio de desenvolvimento) a $0{,}167$ (*broadcast* de menor qualidade técnica). Dado o tamanho reduzido dos conjuntos de validação ($n = 11$ ou 12 chutes por conjunto), os resultados devem ser interpretados como evidência de viabilidade técnica e não como avaliação estatisticamente conclusiva de generalização.

As contribuições do trabalho podem ser organizadas em duas categorias. As contribuições de integração e implementação compreendem: a incorporação do PnLCalib

[Magera et al. 2024], modelo de estado da arte para calibração de câmera em esportes publicado no CVPR 2024, em um *pipeline end-to-end* de análise tática, com adaptação do sistema de coordenadas e implementação de métrica de qualidade baseada em erro de reprojeção; e o retreino especializado do YOLOv8x para detecção de bola sobre o SoccerNet Tracking [Vandeghen et al. 2022], com técnica de recorte dinâmico inspirada no SAHI [Akyon et al. 2022], resultando em melhora de 62% no *recall*.

As contribuições técnicas próprias compreendem: o desenvolvimento do BallKalmanTracker, que combina filtragem de Kalman com *gate* de Mahalanobis, *Optical Flow* [Lucas and Kanade 1981] como preditor durante oclusões, filtro geométrico de falsos positivos e verificação de estacionaridade; e a implementação do XGNet em PyTorch [Paszke et al. 2019] com arquitetura de quatro camadas ocultas, *BatchNorm*, *Dropout* e calibração por *Platt Scaling* [Platt 1999], treinado com *GroupShuffleSplit* por partida para garantia de ausência de *data leakage*. O módulo de refinamento de posição da bola baseado em regressão de *heatmap* gaussiano com U-Net [Ronneberger et al. 2015] e *encoder* MobileNetV2 [Sandler et al. 2018], embora tenha atingido distância euclidiana média de $0{,}64$ *pixels* e PCK@0.1 de $99{,}6\%$ em avaliação isolada, não foi integrado ao *pipeline* final devido a *domain shift* identificado na integração em cascata, sendo documentado como resultado negativo que direciona trabalhos futuros.

5.1. Limitações

O sistema apresenta limitações que devem ser consideradas na interpretação dos resultados e na aplicação prática. A limitação mais impactante é a dependência da qualidade de detecção da bola, identificada como gargalo primário em todos os cinco conjuntos de validação: quatro dos onze falsos negativos do conjunto BEL-ITA são causados diretamente pela falha do detector de bola, e nos conjuntos sul-americanos (FLA-CAP e SAN-MIR) essa limitação é amplificada pelo *domain shift* entre o domínio de treinamento do YOLOv8x especializado, composto predominantemente por *broadcast* europeu, e as características visuais das transmissões brasileiras.

O modelo XGNet utiliza apenas seis *features* espaciais, subconjunto restrito em relação aos modelos comerciais de xG. A ausência de *features* como posição do goleiro, tipo de ação precedente e velocidade da bola no momento do chute limita a capacidade do modelo de distinguir situações táticas de alta periculosidade que a geometria pura da finalização não captura.

O rastreamento de jogadores opera sem módulo de Re-ID, contaminando ocasionalmente a estimativa de pressão defensiva em oclusões prolongadas. O módulo de *heatmap* gaussiano, embora preciso em avaliação isolada, apresentou limitações de integração por *domain shift*, sendo mantido fora do *pipeline* de produção. Por fim, o protocolo de validação, com 11 ou 12 chutes por conjunto, apresenta poder estatístico insuficiente para comparações conclusivas, sendo a expansão do conjunto de validação a principal prioridade metodológica para trabalhos futuros.

5.2. Trabalhos Futuros

A partir das limitações identificadas e dos resultados obtidos nesta pesquisa, vislumbram-se diversas oportunidades de expansão e aprimoramento técnico para o *pipeline* desenvolvido. Para nortear a continuidade desta linha de investigação, propõem-se as seguintes frentes de trabalhos futuros:

- *Fine-tuning* do YOLOv8x com dados do futebol brasileiro para mitigar o *domain shift*.
- Resolução do *domain shift* na integração em cascata do módulo de heatmap U-Net.
- Inclusão da velocidade da bola (vinda do rastreamento) como feature no XGNet.
- Integração do módulo de Re-ID do BotSORT para manter a consistência pós-oclusão.
- Expansão do conjunto de validação com dados de competições e cenários diversos.

Referências

Aharon, N., Orfaig, R., and Bobrovsky, B.-Z. (2022). BoT-SORT: Robust associations multi-pedestrian tracking.

Akyon, F. C., Altinuc, S. O., and Temizel, A. (2022). Slicing aided hyper inference and fine-tuning for small object detection. In *IEEE International Conference on Image Processing (ICIP)*.

Chen, T. and Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*.

Deloitte (2023). Annual review of football finance 2023. Technical report, Deloitte Sports Business Group.

Goodfellow, I., Bengio, Y., and Courville, A. (2016). *Deep Learning*. MIT Press.

Hewitt, J. H. and Karakuş, O. (2023). A machine learning approach for player and position adjusted expected goals in football (soccer). *Franklin Open*, 4.

Homayounfar, N., Fidler, S., and Urtasun, R. (2017). Sports field localization via deep structured models. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*.

Jocher, G., Chaurasia, A., and Qiu, J. (2023). Ultralytics YOLO. `https://github.com/ultralytics/ultralytics`. Versão 8.0.0.

Kalman, R. E. (1960). A new approach to linear filtering and prediction problems. *Journal of Basic Engineering*.

Link, D. (2018). *Data Analytics in Football: Positional Data Collection, Modelling and Analysis*. Routledge.

Lucas, B. D. and Kanade, T. (1981). An iterative image registration technique with an application to stereo vision. In *IJCAI*.

Magera, F., Herold, J., Cioppa, A., Somm, T., Milla, Z., Giancola, S., Gade, R., Moeslund, T. B., Van Droogenbroeck, M., and Orban de Xivry, J.-J. (2024). A robust framework for camera calibration in sports. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*.

Paszke, A. et al. (2019). PyTorch: An imperative style, high-performance deep learning library. In *Advances in Neural Information Processing Systems (NeurIPS)*.

Platt, J. C. (1999). Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods. In *Advances in Large Margin Classifiers*. MIT Press.

Redmon, J., Divvala, S., Girshick, R., and Farhadi, A. (2016). You only look once: Unified, real-time object detection. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*.

Reep, C. and Benjamin, B. (1968). Skill and chance in association football. *Journal of the Royal Statistical Society*.

Ronneberger, O., Fischer, P., and Brox, T. (2015). U-Net: Convolutional networks for biomedical image segmentation. In *International Conference on Medical Image Computing and Computer-Assisted Intervention (MICCAI)*.

Sandler, M., Howard, A., Zhu, M., Zhmoginov, A., and Chen, L.-C. (2018). MobileNetV2: Inverted residuals and linear bottlenecks. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*.

Sun, K., Xiao, B., Liu, D., and Wang, J. (2019). Deep high-resolution representation learning for visual recognition. *IEEE Transactions on Pattern Analysis and Machine Intelligence*.

Tippett, J. (2019). *The Expected Goals Philosophy*. Independently Published.

Vandeghen, R. et al. (2022). SoccerNet-Tracking: A world-class dataset for soccer ball and player tracking. In *CVPR Workshops*.

Zhang, Y., Sun, P., Jiang, Y., Yu, D., Weng, F., Yuan, Z., Luo, P., Liu, W., and Wang, X. (2022). ByteTrack: Multi-object tracking by associating every detection box. In *European Conference on Computer Vision (ECCV)*.

Apêndice A — Siglas e Nomenclaturas

A Tabela 6 apresenta as siglas e nomenclaturas técnicas utilizadas ao longo deste trabalho, organizadas em ordem alfabética.

Tabela 6: Siglas e nomenclaturas utilizadas no texto.

Sigla / Termo	Significado
Adam	*Adaptive Moment Estimation*, otimizador de gradiente adaptativo
AUC-ROC	*Area Under the Receiver Operating Characteristic Curve*, área sob a curva ROC
BatchNorm	*Batch Normalization*, normalização por lote durante o treinamento
BCEWithLogitsLoss	*Binary Cross-Entropy with Logits Loss*, função de perda para classificação binária com logits
BoT-SORT	*Robust Associations Multi-Pedestrian Tracking*, algoritmo de rastreamento multi-objeto
Brier Score	Erro quadrático médio entre probabilidades previstas e desfechos observados
ByteTrack	Algoritmo de rastreamento multi-objeto por associação de todas as detecções
CNN	*Convolutional Neural Network*, rede neural convolucional
COCO	*Common Objects in Context*, benchmark de detecção de objetos
Dropout	Técnica de regularização que desativa neurônios aleatoriamente durante o treinamento
Data leakage	Vazamento de dados entre conjuntos de treino e teste
Early stopping	Interrupção antecipada do treinamento ao cessar melhora na métrica de validação
F1-Score	Média harmônica entre Precisão e Recall
Faster R-CNN	*Faster Region-based Convolutional Neural Network*, detector de objetos por proposta de regiões
FN	Falso Negativo, evento real não detectado pelo sistema
FP	Falso Positivo, detecção do sistema que não corresponde a um evento real
Freeze frame	Quadro congelado com posições dos jogadores no momento do chute (StatsBomb)
GroupShuffleSplit	Estratégia de divisão treino/teste com agrupamento por unidade (partida)
HRNet	*High-Resolution Network*, arquitetura de rede para detecção de pontos-chave
IoU	*Intersection over Union*, razão entre área de sobreposição e área de união de duas *bounding boxes*
Kalman Filter	Filtro de Kalman, estimador recursivo ótimo para sistemas lineares com ruído gaussiano
mAP50	*Mean Average Precision* com limiar de IoU de $0{,}50$
mAP50-95	*Mean Average Precision* agregado sobre limiares de IoU entre $0{,}50$ e $0{,}95$
MobileNetV2	Arquitetura de rede neural leve para dispositivos móveis, usada como *encoder*
MOT	*Multi-Object Tracking*, rastreamento multi-objeto
NMS	*Non-Maximum Suppression*, supressão de detecções redundantes sobrepostas
Optical Flow	Fluxo óptico, estimativa do deslocamento aparente de regiões entre quadros consecutivos
PCK@0.1	*Percentage of Correct Keypoints* com limiar de 10% do tamanho do objeto
Pipeline	Sequência de módulos de processamento encadeados
Platt Scaling	Calibração de probabilidades por regressão logística sobre os logits do modelo
PnLCalib	*Point-and-Line Calibration*, modelo de calibração de câmera em esportes
Precisão	Proporção de detecções corretas entre todas as detecções realizadas pelo sistema
Re-ID	*Re-Identification*, módulo de reidentificação de objetos após oclusão
Recall	Proporção de eventos reais efetivamente detectados pelo sistema
ReduceLROnPlateau	*Scheduler* que reduz a taxa de aprendizado ao cessar melhora na *loss*
SAHI	*Slicing Aided Hyper Inference*, técnica de recorte dinâmico para objetos pequenos
TN	Verdadeiro Negativo, clipe de controle corretamente classificado como ausente de finalização
TP	Verdadeiro Positivo, finalização real corretamente detectada pelo sistema
U-Net	Arquitetura de rede neural para segmentação e regressão de *heatmap*
xG	*Expected Goals*, probabilidade estimada de um chute resultar em gol
XGBoost	*Extreme Gradient Boosting*, modelo de aprendizado de máquina baseado em árvores
XGNet	Rede neural profunda proposta neste trabalho para modelagem de *Expected Goals*
YOLO	*You Only Look Once*, família de detectores de objetos em tempo real
YOLOv8x	Variante extra-large do detector YOLOv8 da Ultralytics